PROJET FINAL · SCIENCE DES DONNÉES · S7MOI1

Garder ses joueurs avant qu'ils partent

Prédire le churn dans un jeu en ligne par abonnement, à partir de 10,8 millions de connexions World of Warcraft (2008)

Mattéo Gayvallet
ECAM-EPMI · 2AE

Yann Skonieczny
Intervenant

Octobre 2026
Rapport de synthèse

RÉSUMÉ EXÉCUTIF

Nous proposons de remplacer la relance des joueurs absents depuis plus de 14 jours par un ciblage trimestriel fondé sur un modèle de prédiction du départ. Sur une période jamais vue (été 2008), le modèle repère 82 % des joueurs qui partent, contre 48 % pour la règle actuelle, et 56 % de ses offres touchent des joueurs réellement sur le départ. Sous nos hypothèses, le gain est d'environ 52 000 € par an et par serveur pour un projet à 35 000 € (ROI de 50 % la première année) ; nous recommandons un pilote avec groupe témoin pour mesurer l'efficacité réelle de l'offre, hypothèse dont dépend le plus le résultat.

82 %
des départs repérés sur le test
(règle actuelle : 48 %)

0,776
PR-AUC en validation croisée
(hasard : 0,314)

13,1 k€
économisés par campagne et par serveur

50 %
de ROI la 1re année, retour en 8 mois

SOMMAIRE

1 Cadrage de la problématique métier
2 Type de problématique
3 Analyse et préparation des données
4 Développement du modèle
5 Choix des métriques
6 Justification métrique et business
7 ROI potentiel
8 Présentation des résultats
9 Risques et enjeux
A Annexes : reproductibilité, sources, usage de l'IA

1 Cadrage de la problématique métier

AXE 1

Quelle décision l'entreprise veut-elle mieux prendre ? **À chaque trimestre, choisir à quels joueurs actifs offrir un mois d'abonnement pour éviter qu'ils ne partent.**

Contexte	Un éditeur exploite un jeu en ligne massivement multijoueur financé par abonnement mensuel (12,99 €), sur le modèle de World of Warcraft. L'utilisateur du résultat est l'équipe rétention (CRM), qui gère les offres envoyées aux joueurs.
Problème	Des joueurs cessent de se connecter puis résilient. L'éditeur perd des revenus récurrents et s'en aperçoit une fois le joueur parti.
Décision et horizon	À une date de coupure, classer les joueurs actifs selon leur risque de ne plus revenir dans les **3 mois**, puis envoyer une offre de rétention aux plus à risque.
Situation actuelle	Relance des joueurs absents depuis plus de 14 jours. Cette règle sert de **référence** à battre, avec deux bornes : ne rien faire, ou faire une offre à tout le monde.
Critère de succès	Sur une période jamais vue : repérer **au moins 70 %** des départs (Recall), avec **au plus 2 offres inutiles pour 1 utile** (Precision ≥ 33 %), et un coût de campagne inférieur à celui de la règle actuelle.
Contraintes	Seules les connexions antérieures à la coupure sont utilisables. Le ciblage doit rester explicable à l'équipe rétention. Les historiques de connexion sont des données personnelles (identifiants anonymisés ici).

2 Type de problématique

AXE 2

La cible est `churn_3m` : elle vaut 1 si un joueur actif dans les 30 jours précédant la coupure n'apparaît plus du tout dans les 3 mois qui suivent, et 0 sinon. Elle est connue pour tout l'historique : le problème est **supervisé**. Elle ne prend que deux valeurs : c'est une **classification binaire**.

- **Régression écartée** : prédire une date de départ ou une durée n'apporte rien à une décision binaire (envoyer une offre ou non), et sa sortie n'est pas une probabilité bornée.
- **Analyse de survie écartée** à ce stade : pertinente pour modéliser le délai avant départ, elle n'est pas nécessaire pour décider qui cibler à une date donnée.
- **Clustering écarté** : il ignorerait l'étiquette que l'on sait construire.

La classe positive représente 31 % des joueurs à l'entraînement : le déséquilibre est modéré, mais il exclut l'accuracy comme métrique principale (axe 5).

3 Analyse et préparation des données

AXE 3

3.1 Description

Le jeu **World of Warcraft Avatar History** (Lee et al., ACM MMSys 2011) est issu de relevés de la commande `/who` effectués toutes les dix minutes sur un serveur de la faction Horde. Il est diffusé gratuitement par ses auteurs et repris sur Kaggle sous licence **CC0 (domaine public)**, consulté le 21/10/2026. Le fichier exploité, `wowah_data.csv`, couvre toute l'année 2008 : **10 826 734 lignes, 7 colonnes, 37 354 personnages**. Chaque ligne signifie « ce personnage était connecté à cet instant » : un relevé représente environ dix minutes de jeu.

Variable	Type	Valeurs	Signification
`char`	entier	identifiant anonymisé	Personnage observé
`level`	entier	1 à 80	Niveau du personnage au moment du relevé
`race`	catégorie	5 races	Race du personnage
`charclass`	catégorie	10 classes	Classe du personnage
`zone`	catégorie	nom de zone	Lieu du jeu où se trouve le personnage
`guild`	entier	identifiant, −1 = aucune	Guilde du personnage
`timestamp`	date-heure	à la seconde	Instant du relevé

3.2 Qualité et décisions de traitement

- **Doublons** : 3 557 lignes strictement identiques (même personnage, même seconde) correspondent à des relevés enregistrés deux fois ; elles sont supprimées.
- **Valeurs manquantes** : aucune au sens strict. La valeur `guild = −1` (15,6 % des relevés) code l'absence de guilde ; c'est une information, transformée en variable `en_guilde`.
- **Incohérence temporelle** : le niveau 80 et la classe Death Knight n'existent qu'après l'extension de novembre 2008, et l'activité bondit en octobre avec la mise à jour qui la prépare (figure 1). Ces mois obéissent à d'autres règles de jeu : ils sont exclus des périodes de modélisation.

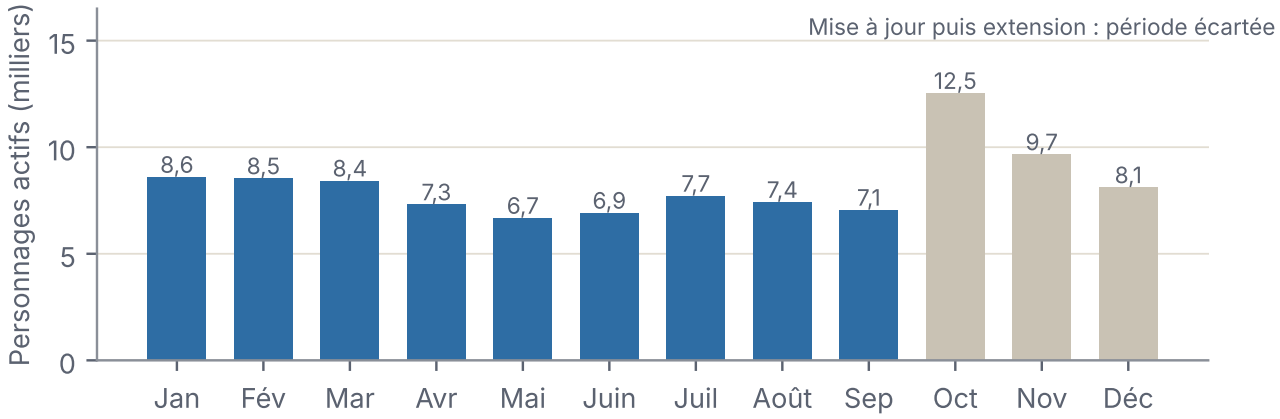


Figure 1. Personnages distincts observés chaque mois. Minimum en mai (6 677), pic en octobre (12 535) : la fin d'année n'est pas représentative et n'est pas utilisée.

3.3 Construction de la cible et découpage chronologique

Le jeu ne contient pas d'étiquette de départ : elle est construite à une **date de coupure**. Les variables sont calculées sur une fenêtre fixe de 90 jours avant la coupure ; la cible observe les 3 mois suivants. Le découpage est chronologique, comme en production : le modèle apprend sur une coupure et il est évalué sur la suivante.

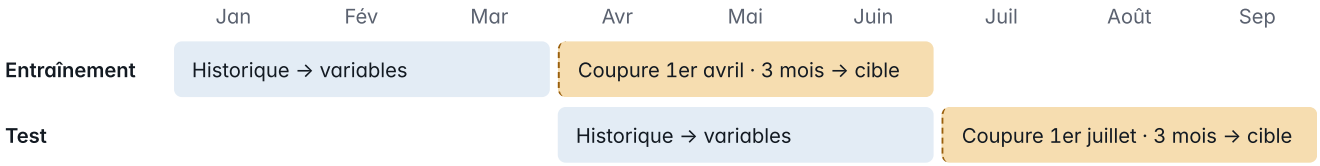


Figure 2. Fenêtres d'observation. passé, utilisé pour les variables futur, utilisé uniquement pour la cible.

Jeu	Coupure	Variables	Cible observée	Joueurs actifs	Taux de départ
Entraînement	1er avril 2008	janv. – mars	avril – juin	8 265	31,4 %
Test	1er juillet 2008	avril – juin	juillet – sept.	6 918	26,1 %

3 870 personnages figurent dans les deux jeux, à des dates différentes : leurs variables sont recalculées et leur cible porte sur une autre période, ce qui reproduit l'usage réel d'un modèle réappliqué chaque trimestre.

3.4 Variables explicatives

Variable	Construction	Justification métier
`jours_depuis_derniere_co`	Coupure – dernier relevé (jours)	Un joueur qui ne se connecte plus est en train de partir
`anciennete_j`	Coupure – premier relevé dans la fenêtre	Les nouveaux venus sont les plus volatils
`jours_actifs_30j`	Jours distincts avec au moins un relevé	Régularité, plus robuste qu'un volume horaire
`releves_7j`, `_30j`, `_30j_precedents`	Nombre de relevés par période (≈ 10 min chacun)	Temps de jeu récent et passé
`tendance_activite` (construite)	Relevés 30 j / (relevés 30 j précédents + 1)	Repère une baisse d'activité avant le départ
`niveau`, `gain_niveau_30j`	Dernier niveau ; progression sur 30 jours	Investissement et progression dans le jeu
`en_guilde` (construite), `nb_guildes`	Dernière guilde ≠ −1 ; guildes distinctes	Le lien social freine le départ
`zones_distinctes_30j`	Zones visitées sur 30 jours	Diversité de l'activité
`race`, `classe`	Dernière valeur connue (catégorielles)	Profil du personnage, contrôle d'équité

3.5 Relations avec la cible

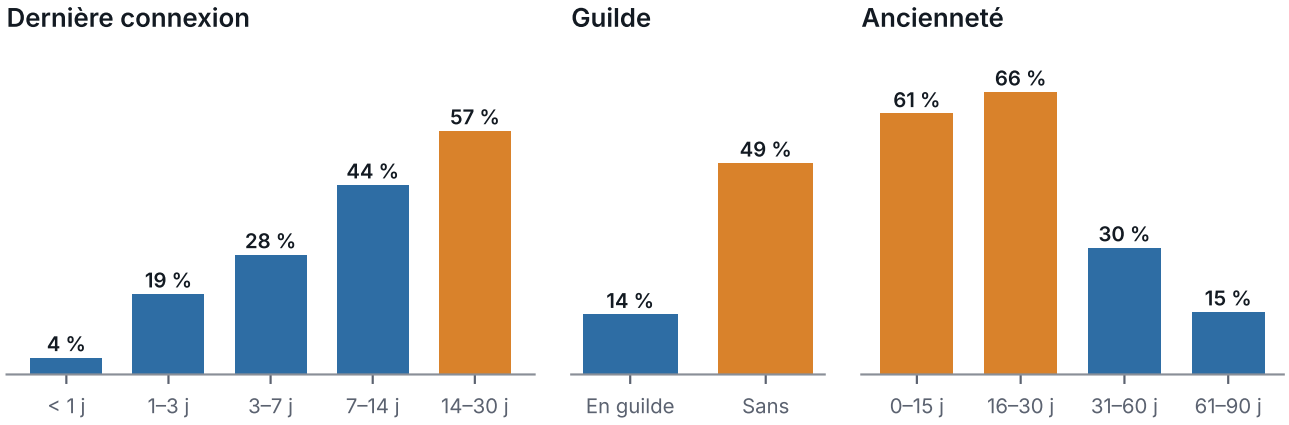


Figure 3. Taux de départ à 3 mois des joueurs actifs en mars (n = 8 265). En orange, les groupes les plus à risque.

- **Récence** : 4 % de départs pour un joueur vu la veille, 57 % pour un joueur absent depuis plus de 14 jours. C'est le signal qu'exploite la règle actuelle, seul.
- **Guilde** : 14 % de départs en guilde contre 49 % sans, soit 3,5 fois plus. C'est un levier actionnable : inciter un joueur isolé à rejoindre une guilde.
- **Ancienneté** : plus de 60 % des personnages apparus depuis moins de 30 jours partent, contre 15 % au-delà de 60 jours. Une partie de ces départs concerne des personnages secondaires abandonnés, limite discutée à l'axe 9.

3.6 Audit de fuite de données

Élément	Risque	Décision
Relevés postérieurs à la coupure	Contiennent la réponse	Utilisés uniquement pour la cible, jamais dans les variables
Mélange aléatoire des périodes	Le futur servirait à prédire le passé	Split chronologique (avril → juillet)
Fenêtre d'historique variable	Ancienneté non comparable entre coupures	Fenêtre fixe de 90 jours
`char`, `date_coupure`	Identifiant mémorisable ; constante	Exclues du modèle
Préparation (imputation, échelle)	Statistiques calculées sur le test	Dans un `Pipeline`, ajusté sur l'entraînement

4 Développement du modèle

AXE 4

4.1 Démarche

Le split chronologique est fait en premier ; le jeu de test n'est utilisé qu'une seule fois, pour le modèle final. Toute la préparation est dans un `Pipeline` scikit-learn : imputation par la médiane et standardisation des 12 variables numériques, encodage one-hot de la race et de la classe. Cinq approches sont comparées en **validation croisée stratifiée à 5 folds** (`random_state = 42`) sur l'entraînement.

```
prep  = ColumnTransformer([("num", Pipeline([("imp", SimpleImputer(strategy="median")),
                                             ("sc", StandardScaler())]), NUM_COLS),
                           ("cat", OneHotEncoder(handle_unknown="ignore"), CAT_COLS)])
model = Pipeline([("prep", prep), ("clf", RandomForestClassifier(random_state=42))])
GridSearchCV(model, {"clf__max_depth": [4, 8, 12, None], "clf__min_samples_leaf": [1, 5, 20]},
             cv=StratifiedKFold(5, shuffle=True, random_state=42), scoring="average_precision")
```

4.2 Comparaison des modèles

Modèle	PR-AUC train	PR-AUC CV	ROC-AUC CV	Recall CV	Precision CV	Lecture
Baseline (classe majoritaire)	0,314	0,314 ± 0,000	0,500	0,000	0,000	Aucun départ repéré
Règle actuelle (absent > 14 j)	—	—	—	0,506	0,570	Référence métier
Régression logistique	0,738	0,736 ± 0,018	0,870	0,667	0,692	Stable, interprétable
Arbre sans `max_depth`	1,000	0,481 ± 0,014	0,705	0,598	0,592	Surapprentissage net
Random Forest (`max_depth` = 8)	0,859	0,770 ± 0,018	0,884	0,608	0,744	Bon compromis
Random Forest réglé	**0,917**	**0,776 ± 0,014**	**—**	**—**	**—**	**Retenu**

Tableau 1. Moyenne ± écart-type sur 5 folds. Recall et Precision au seuil de 0,5 ; le seuil final est choisi par le coût (axe 6). Règle actuelle évaluée sur les mêmes folds.

Tous les modèles battent la baseline, et le Random Forest obtient le meilleur PR-AUC avec une faible variance. Au seuil de 0,5, la régression logistique a un meilleur Recall mais une moins bonne Precision : ces métriques dépendent du seuil, d'où le choix d'une métrique principale qui n'en dépend pas.

4.3 Réglage et diagnostic

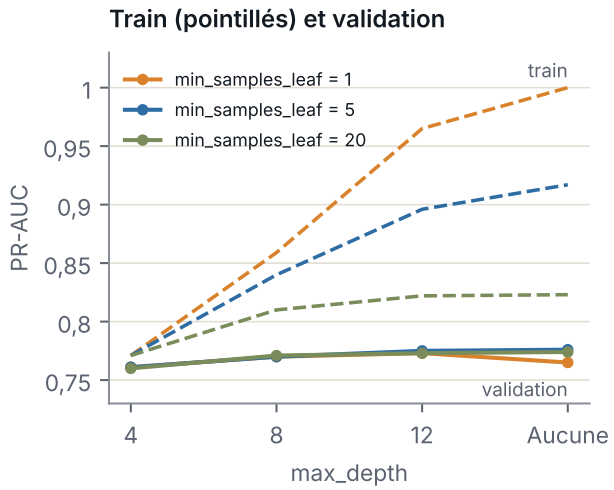


Figure 4. Grille de 12 combinaisons. Le score train grimpe avec la profondeur, la validation plafonne vers 0,77.

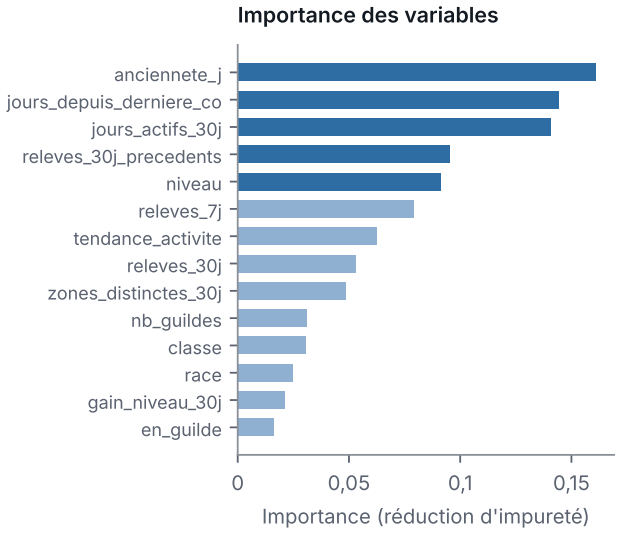


Figure 5. Ancienneté, récence et régularité dominent ; race et classe pèsent environ 3 % chacune.

Sur- et sous-apprentissage. L'arbre non contraint atteint 1,000 en train contre 0,481 en validation : il mémorise les joueurs. Pour le Random Forest, la combinaison retenue (`max_depth = None`, `min_samples_leaf = 5`) obtient 0,776 en validation ; les combinaisons voisines sont à moins d'un écart-type. L'écart train/validation reste visible (0,917 contre 0,776) : une version plus contrainte (`max_depth = 12`, `min_samples_leaf = 20` : 0,822 / 0,773) serait un choix défendable si l'on privilégiait la robustesse.

Importance des variables. Ce sont le comportement et l'engagement qui annoncent un départ, pas le profil du personnage. `en_guilde` paraît faible alors que son lien avec le départ est fort (figure 3) : `nb_guildes` porte presque la même information, et deux variables corrélées se partagent l'importance.

4.4 Analyse des erreurs

Groupe (prédictions hors échantillon, seuil 0,5)	Effectif	Jours depuis dernière co.	Jours actifs / 30	Ancienneté (j)	Niveau	En guilde
Départs repérés (TP)	1 614	15,5	1,6	20,8	9,3	8 %
Départs manqués (FN)	983	12,2	4,1	61,6	31,7	46 %
Fausses alertes (FP)	562	15,6	1,9	28,6	16,3	21 %
Fidèles bien classés (TN)	5 106	5,1	11,5	72,0	47,1	69 %

Les **départs manqués** sont des joueurs « intermédiaires » : anciens, de niveau moyen, modérément actifs, en guilde une fois sur deux. Leur décrochage est peu visible dans l'activité, ce qui suggère d'ajouter des variables d'évolution (baisse de durée des sessions, départ de guilde). Les **fausses alertes** ressemblent aux vrais départs : joueurs occasionnels qui finissent par revenir ; leur coût est chiffré à l'axe 6.

4.5 Évaluation finale sur le test

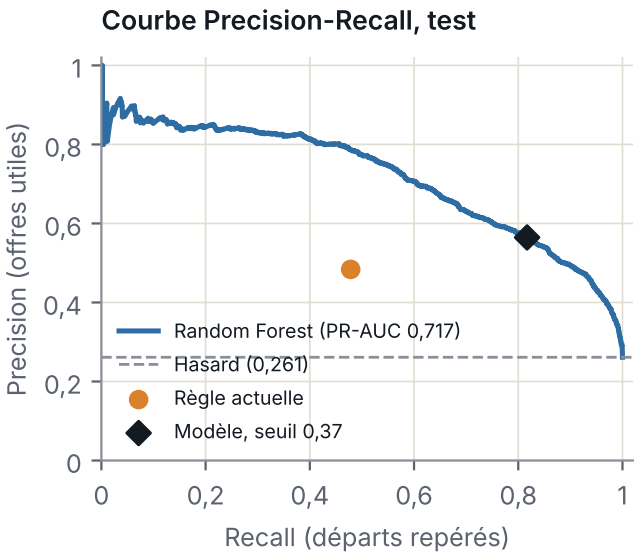


Figure 6. Test (été 2008). La règle actuelle est nettement sous la courbe du modèle.

Le modèle retenu, réentraîné sur toute la coupure d'avril, est évalué **une seule fois** sur la coupure de juillet :

- PR-AUC **0,717** (validation : 0,776 ; hasard : 0,261) ;
- ROC-AUC **0,881**, stable par rapport à la validation (0,884 pour le Random Forest de profondeur 8).

La baisse du PR-AUC est attendue : l'été compte moins de départs (26 % contre 31 %) et constitue une autre période. Le modèle **généralise** d'un trimestre à l'autre. Au seuil retenu à l'axe 6 (0,37), il repère **81,7 %** des départs avec une Precision de **56,5 %** : les deux critères de succès sont atteints.

5 Choix des métriques

AXE 5

- **Métrique principale : PR-AUC** (`average_precision`). Elle mesure la capacité à classer les joueurs qui partent avant les autres, indépendamment du seuil, et elle est plus exigeante que la ROC-AUC quand la classe positive est minoritaire. Sa valeur de référence (hasard) est le taux de départ, ce qui la rend facile à lire.
- **Garde-fous**, liés au critère de succès : **Recall** (part des départs repérés, ≥ 70 %), car un départ manqué coûte un an d'abonnement ; **Precision** (part des offres utiles, ≥ 33 %), car chaque offre a un coût. La ROC-AUC et le F1 sont suivis à titre indicatif.
- **Accuracy écartée** : un modèle qui prédit toujours « reste » atteint 69 % d'accuracy à l'entraînement sans repérer un seul départ.

6 Justification métrique et business

AXE 6

6.1 Matrice de coûts

Hypothèse	Valeur
Abonnement mensuel (prix public, source RTBF)	12,99 €
Durée de vie supplémentaire d'un joueur retenu	12 mois
Valeur d'un joueur retenu (12 × 12,99 €)	155,88 €
Coût d'une offre (un mois offert)	12,99 €
Taux de réussite de l'offre (à valider)	25 %

Cas	Conséquence	Coût
FN	Départ non repéré : valeur perdue	155,88 €
TP	Offre ; 75 % partent quand même	129,90 €
FP	Offre à un joueur fidèle	12,99 €
TN	Rien	0 €

> Coût total = FN × 155,88 + TP × (12,99 + 0,75 × 155,88) + FP × 12,99

Repérer un départ fait économiser 25,98 € (155,88 − 129,90), une fausse alerte en coûte 12,99. Cibler un joueur est donc rentable dès que sa probabilité de départ dépasse 12,99 / (0,25 × 155,88) ≈ **0,33**, si les probabilités étaient parfaitement calibrées.

6.2 Choix du seuil

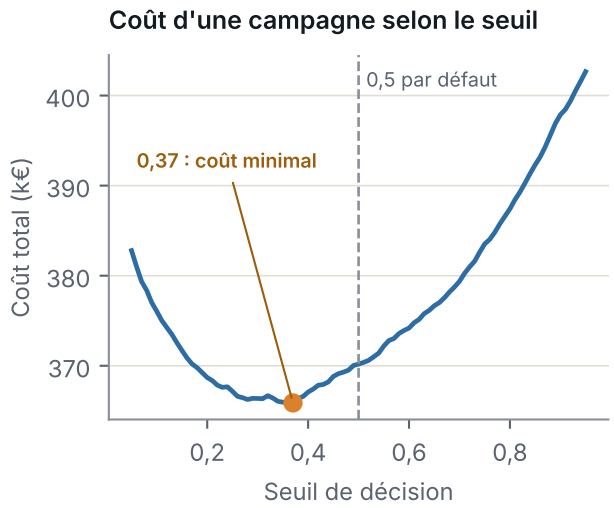


Figure 7. Coût d'une campagne sur l'entraînement (probabilités hors échantillon).

Seuil	TP	FP	FN	Prec.	Recall	Coût
0,20	2 400	2 019	197	54 %	92 %	368,7 k€
0,30	2 202	1 444	395	60 %	85 %	366,4 k€
0,37	**2 044**	**1 090**	**553**	**65 %**	**79 %**	**365,9 k€**
0,50	1 614	562	983	74 %	62 %	370,2 k€
0,70	1 078	197	1 519	85 %	42 %	379,4 k€

Le seuil est choisi **sur l'entraînement**, sans regarder le test. Le seuil 0,7 a la meilleure Precision mais coûte environ 13 500 € de plus par campagne : il laisse partir trop de joueurs. La courbe est plate entre 0,3 et 0,45, le choix n'est donc pas fragile.

Traduction métier (test, seuil 0,37). Sur 100 joueurs qui partent, le modèle en repère 82, contre 48 avec la règle actuelle. Sur 100 offres envoyées, 56 vont à des joueurs réellement sur le départ, contre 48. Il envoie 2 616 offres sur 6 918 joueurs actifs (règle : 1 788) : 1 477 départs repérés, 331 manqués, 1 139 offres à des joueurs qui seraient restés.

7 ROI potentiel

AXE 7

Hypothèses supplémentaires. Périmètre d'un serveur d'environ 7 000 joueurs actifs ; une campagne par trimestre, chacune supposée comparable au test ; référence : la règle actuelle. Coût du projet la première année : 25 000 € de développement (environ deux mois de data scientist) et 10 000 € d'exploitation (calcul trimestriel, suivi, réentraînement), soit **35 000 €**.

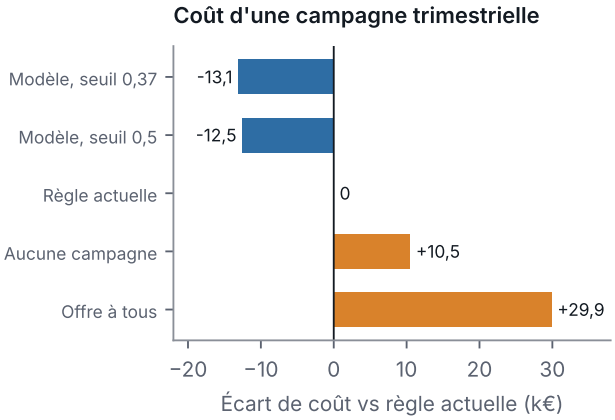


Figure 8. Écart de coût d'une campagne par rapport à la règle actuelle, test (été 2008).

Calcul	Valeur
Coût d'une campagne, règle actuelle	271 348 €
Coût d'une campagne, modèle (0,37)	258 254 €
Gain par campagne	13 094 €
Gain annuel (4 campagnes)	52 376 €
Coût du projet, 1re année	35 000 €
ROI 1re année	**50 %**
Délai de retour	**8,0 mois**

> ROI = (52 376 − 35 000) / 35 000 = 50 % · Délai de retour = 35 000 / (52 376 / 12) = 8,0 mois

Le coût d'une campagne inclut les revenus perdus des joueurs qui partent, qu'aucune stratégie n'évite entièrement : seule compte la différence entre stratégies. Faire une offre à tout le monde est la pire option (+29,9 k€ par campagne) ; ne rien faire coûte 10,5 k€ de plus que la règle actuelle.

Analyse de sensibilité

Scénario	Seuil ré-optimisé	Gain annuel	ROI 1re année	Retour
Central (offre efficace à 25 %, joueur retenu 12 mois)	**0,37**	**52 376 €**	**50 %**	**8,0 mois**
Pessimiste : offre efficace à 15 %	0,54	33 753 €	−4 %	12,4 mois
Pessimiste : joueur retenu 6 mois	0,67	36 112 €	3 %	11,6 mois
Optimiste : offre efficace à 35 %	0,22	86 337 €	147 %	4,9 mois
Bonus en jeu à 3 €, efficace à 10 %	0,17	28 614 €	−18 %	14,7 mois

Dans les scénarios pessimistes, le projet est tout juste à l'équilibre la première année, puis rentable dès la deuxième, le développement n'étant payé qu'une fois. Une offre moins chère n'est pas forcément meilleure : un bonus en jeu à 3 € retient sans doute bien moins qu'un mois offert, puisqu'on ne peut pas jouer sans abonnement ; à 10 % d'efficacité, il n'est pas rentable la première année. Le résultat dépend surtout du **taux de réussite de l'offre** : c'est l'hypothèse à valider en priorité, par un test A/B. Le calcul porte sur un seul serveur ; un éditeur en exploite des dizaines, ce qui partagerait le coût du projet si le modèle se généralise.

8 Présentation des résultats

AXE 8

La soutenance s'adresse à un décideur non spécialiste accompagné d'un expert. Elle suit l'ordre problème → données → démarche → résultats → valeur → limites, en 15 diapositives sans code, chacune portant un message unique et des chiffres issus des notebooks. Les visuels attendus y figurent : schéma de la démarche, tableau comparatif des modèles, matrice de confusion, coût selon le seuil, tableau de ROI et de sensibilité.

Recommandation. Remplacer la relance après 14 jours d'absence par un ciblage trimestriel fondé sur le modèle, au seuil choisi par le coût, après un pilote d'une campagne avec groupe témoin. En production : raisonner au niveau du compte d'abonnement, et suivre le Recall et le coût à chaque trimestre.

9 Risques et enjeux

AXE 9

Risque	Catégorie	Probabilité	Impact	Mesure de réduction
Taux de réussite réel de l'offre inférieur à 25 %	Métier	Moyenne	Élevé	Pilote avec groupe témoin avant généralisation
Dérive après une extension ou une mise à jour majeure	Technique	Élevée	Élevé	Suivi trimestriel du PR-AUC et du Recall ; réentraînement à chaque coupure
Un personnage n'est pas un joueur : plusieurs personnages par compte faussent la cible	Technique	Élevée	Moyen	En production, travailler au niveau du compte d'abonnement
Un seul serveur, une seule faction	Technique	Certaine	Moyen	Valider sur d'autres serveurs avant tout déploiement
Effet d'aubaine : des joueurs attendent l'offre	Métier	Moyenne	Moyen	Une offre par joueur et par an ; offres variées
Fatigue des équipes ou des joueurs face aux relances	Opérationnel	Faible	Moyen	Seuil calibré sur le budget ; envoi automatisé
Données personnelles (historique de connexion)	Éthique, RGPD	Faible	Élevé	Identifiants anonymisés, finalité limitée à la rétention, information dans les CGU
Ciblage perçu comme inéquitable	Éthique	Faible	Moyen	Race et classe pèsent ≈ 3 % chacune ; règle documentée et explicable
Coût énergétique	Environnement	Faible	Faible	Modèle léger (≈ 1 minute d'entraînement sur un portable), 4 calculs par an

Limites et suite

Les données décrivent un serveur en 2008 et suivent des personnages, non des comptes : le taux de départ observé surestime probablement les résiliations réelles. Les coûts reposent sur des hypothèses explicites, dont la plus critique, l'efficacité de l'offre, doit être mesurée. Prochaines étapes : variables d'évolution récente pour mieux repérer les joueurs « intermédiaires », calibration des probabilités, et validation temporelle glissante sur plusieurs coupures.

A Annexes

REPRODUCTIBILITÉ · SOURCES · IA

A.1 Reproductibilité

```
projet-churn-wow/
├── README.md
├── requirements.txt
├── data/                 # données (cf. data/README)
├── notebooks/
│   ├── 01_cadrage_eda.ipynb
│   ├── 02_modelisation.ipynb
│   └── 03_decision_roi.ipynb
├── src/
│   ├── features.py       # variables, cible
│   └── modeling.py       # pipeline, coûts
└── reports/              # figures, prédictions
```

Les notebooks s'exécutent dans l'ordre (01, 02, 03) avec *Restart & Run All*, en chemins relatifs, avec `random_state = 42`. Le fichier de données (643 Mo) dépasse la limite de 50 Mo : il est téléchargé depuis Kaggle et placé dans `data/`. Versions : Python 3.13, pandas 3.0.5, numpy 2.5.3, scikit-learn 1.9.1, matplotlib 3.11.2. Durée totale d'exécution : environ 3 minutes sur un ordinateur portable.

Les chiffres de ce rapport et de la soutenance sont ceux produits par les notebooks.

A.2 Sources

- Y.-T. Lee, K.-T. Chen, Y.-M. Cheng, C.-L. Lei, « World of Warcraft Avatar History Dataset », *ACM Multimedia Systems Conference* (MMSys), 2011. Données diffusées gratuitement par les auteurs.
- Kaggle, « World of Warcraft Avatar History », kaggle.com/mylesoneill/warcraft-avatar-history, licence CC0 (domaine public), consulté le 21/10/2026.
- RTBF, « World of Warcraft : pourquoi le prix de l'abonnement ne devrait jamais augmenter » (prix de 12,99 € par mois).
- Y. Skonieczny, *Projet final — De la donnée à la décision*, feuille de consignes, ECAM-EPMI, 2026.

A.3 Usage de l'IA générative

Claude (Anthropic) a été utilisé comme assistant pour le choix du sujet et du jeu de données, la structuration du dépôt, une première version du code et des notebooks, ainsi que pour la mise en forme de ce rapport et de la soutenance. Le code a été relu, exécuté et compris par l'auteur ; les choix de modélisation et les hypothèses sont assumés et justifiés dans ce document.